1. 팀 정보

과제명	해외여행 중 악성 QR 의 위험으로부터 사용자의 안전한 접속을 돕는 스마트 어시스턴트
팀 정보	33 팀(할수있다 능)
구성원	2376322 황규리(BE/AI), 2317016 신예진(FE/AI), 2271022 김태연(FE/AI)
지도 교수	심재형 교수님

2. 과제 요약

2.1. 필요성 및 배경

(1) 큐싱 보안 위협 현황

코로나 팬데믹을 거치며 전 세계적으로 QR 코드 활용이 폭발적으로 증가하였다. 글로벌 QR 코드 생성량은 2020 년 대비 꾸준히 상승해 2022 년에는 약 87% 증가하는 등 QR 은 이제 결제·주문·인증 등 일상 전반에서 보편적인 접근 수단으로 자리 잡았다. 그러나 QR 사용이 확대된 만큼 이를 악용한 큐싱(Quishing) 역시 빠르게 증가하고 있다. 큐싱은 QR 에 악성 URL 을 심어 사용자가 스캔하는 순간 피싱 사이트로 연결시키는 공격으로, 코로나 기간 동안 13 만 건 이상의 피싱 URL 이 생성되었고 2023 년 국내 QR 피싱 피해는 전년 대비 60% 증가하였다.

(2) 해외여행 맥락의 보안 취약성

팬데믹 이후 해외여행 수요는 급격히 회복되며 2024 년 기준 국민 해외관광객 수는 팬데믹 이전 수준을 넘어섰다. 여행지에서는 장소 안내, 티켓 발권 등 다양한 상황에서 QR 사용이 필수적이지만, 언어 장벽, 낯선 환경 등으로 인해 여행자는 QR 스캔 시 URL 의 진위를 스스로 판단하기 어렵다. 최근 동남아·유럽 지역에서 여행객을 노린 QR 결제 사기가 급증하고 있다는 보도 역시 이러한 취약성을 뒷받침한다. 즉, 전 세계적 QR 사용 증가와 해외여행 재개, 그리고 여행자 특유의 정보 취약성이 결합되며 해외여행자는 큐싱 공격의 주요 표적이 되고 있다.

2.2. 기존 연구와의 비교

현존하는 큐싱 방지 서비스들을 비교한 후 공통적으로 갖는 한계점을 분석해보았고, 관련 논문을 참고하여 기술적인 한계를 보완할 만한 방법에 대한 조사를 진행했다.

(1) 기존 서비스 비교 및 한계

‘KT 안심 QR’ 서비스는 KT 가 2024 년에 출시한 큐싱 예방 서비스로, ‘마이케이티’라는 앱을 통해 이용할 수 있다. 해당 서비스는 블랙리스트 기반으로 동작하며, 이미 알려진 악성 URL 에 대해 사후적으로 차단하는 방식이다. ‘KISA 보호나라’는 한국인터넷진흥원에서 운영하는 보안 서비스로, 카카오톡 ‘보호나라’ 채널에서 큐싱 메뉴를 제공한다. 해당 채널에서 사용자가 의심되는 URL 이나 QR 코드를 직접 신고하면 이를 분석하여 악성 여부를 확인해주는 구조이다.

KT 안심 QR 서비스의 경우에는 데이터베이스에 기반한 탐지 구조를 가지기 때문에, 새롭게 등장하는 악성 URL 에 대해 즉각적인 대응이 어렵다는 한계를 가진다.'KISA 보호나라'의 경우에는 카카오톡 채널을 통해 제공되는 서비스이기 때문에 접근성이 좋지 않고, 단순히 악성 여부만 확인할 수 있으며, 구체적인 분석 결과나 판단 근거를 알 수 없다는 한계를 가진다. 또한, 두 서비스 모두 국내를 중심으로 운영되기 때문에 해외 사이트나 글로벌 환경에서 발생하는 QR 기반 위협에 대한 대응 범위가 제한적이다.

(2) 참고 논문

단순 DB 및 블랙리스트 기반 탐지 구조의 한계를 보완하기 위해, QR 코드로 연결되는 URL 의 구조적 특징을 분석하는 머신러닝 기반 탐지 기법에 관한 선행 연구를 검토했다.

첫 번째로 참고한 논문은 「URL 주요특징을 고려한 악성 URL 머신러닝 탐지모델 개발」[1]이다. 해당 연구는 다양한 머신러닝 알고리즘을 적용한 실험에서 높은 정확도와 F1-score 를 보이며, URL 의 구조적 특징을 활용한 탐지 기법의 효과성을 검증하였다. 이를 통해 URL 기반 특징 분석이 악성 URL 탐지에 있어 유의미하고 타당한 접근 방식임을 확인할 수 있었다. 또한 해당 연구에서는 문자열 기반 피처를 추출하여 악성 여부를 판단하는 방식을 제안하였으며, 본 프로젝트 이러한 방식을 참고하여 URL 의 문자열 기반 피처를 설계하였다.

「다중 머신러닝 알고리즘을 이용한 악성 URL 예측 시스템 설계 및 구현」[2]에서는 단일 머신러닝 모델의 성능 개선을 위해, 여러 모델의 예측 결과를 결합하는 다중 모델 기반 접근 방식을 제안하였다. 다중 모델 조합을 적용한 경우 단일 모델 대비 예측 정확도가 향상되는 결과를 보였으며, 모델 간 조합에 따라 성능 차이가 발생한다는 점을 통해 적절한 모델 선택과 조합이 중요함을 확인할 수 있었다. 해당 논문에서 나타난 모델 조합별 성능 차이를 토대로 본 프로젝트에서도 모델 앙상블을 진행하였다.

2.3. 핵심 아이디어 및 솔루션

현재 있는 큐싱 방지 서비스의 경우 단순 DB 에 기반하여 판단하고 있어 새로운 악성 URL 의 경우 걸러낼 수 없다는 문제점이 존재한다. 또한 외국어로 된 웹사이트의 내용을 이해할 수 없어 해당 사이트의 목적 및 위험 여부를 알 수 없으며 해외 환경에서 사기나 정보 유출 위험에 대한 불안감을 가지게 된다는 문제점이 존재한다.

본 프로젝트는 AI 기반 URL 분석 모델을 활용하여 QR 스캔 시 발생하는 피싱 위험을 차단하고 사이트 내용 이해를 돕는 스마트 어시스턴트를 목적으로 한다 핵심 아이디어는 다음과 같다.

(1) 머신러닝 기반 악성 URL 탐지

URL 구조 분석과 도메인 정보를 피처로 하는 URL 분류 앙상블 모델로 정상/악성을 판별한다. 해외여행과 관련된 URL 로 모델을 파인 튜닝해 여행 시 마주할 URL 에 특화된 모델을 만든다. 사용자가 QR 코드를 스캔하면 해당 URL 의 위험도 판단 결과를 직관적으로 제공하며, XAI(설명 가능한 AI)를 적용해 사용자 수준에 맞는 이해 가능한 판단 근거를 함께 제시한다. 또한 리다이렉션 로그를 분석하여 중간 경유지부터 최종 목적지까지의 위험 요소를 추적함으로써, 보다 신뢰도 높은 보안 정보를 제공한다.

---

[1] 김영준, 이재우. (2022). URL 주요특징을 고려한 악성 URL 머신러닝 탐지모델 개발. 한국정보통신학회논문지, 26(12), 1786-1793.

[2] 강홍구, 신삼신, 김대엽, and 박순태. "다중 머신러닝 알고리즘을 이용한 악성 URL 예측 시스템 설계 및 구현." 멀티미디어학회논문지 23.11 (2020): 1396-1405.

(2) 웹 뷰 기반 보안 브라우저

사용자가 QR 코드를 통해 웹페이지에 접속할 때, 격리된 보안 환경에서 URL 을 로드하는 보호 계층을 제공한다. 추가로 웹페이지 번역, 위험문구 안내 등을 통해 내용 이해를 돕는다.

2.4. 기대 효과 및 의의

본 프로젝트는 해외여행자의 QR 피싱 피해를 예방하고, 보안 인식 향상 및 정보 접근성을 개선하는 것을 목표로 한다. 기존 서비스 대비 다음과 같은 효과를 기대할 수 있다.

(1) QR 피싱 대응 과정 단순화 및 사전 차단 강화

기존에는 사용자가 QR 코드 스캔 후 URL 의 안전성을 직접 판단하거나, 별도의 보안 서비스를 통해 확인해야 하는 불편함이 존재한다. 본 서비스는 QR 스캔 → 위험도 분석 → 경고 제공까지의 과정을 단일 흐름으로 통합하여, 기존 대비 보안 확인 절차를 2~3 단계 이상 감소시킬 수 있다.

(2) 사용자 보안 판단 부담 감소 및 대응 유도

기존에는 URL 구조, 도메인 등을 사용자가 직접 해석해야 하기 때문에 일반 사용자가 위험 여부를 판단하기 어렵다. 본 서비스는 XAI 기반 설명과 대응 가이드를 제공하여, 사용자의 주관적 판단 의존도를 낮추고, 실제 행동(접속 중단, 주의 등)으로 이어질 가능성을 높인다.

(3) 언어 장벽으로 인한 위험 노출 감소

해외 웹페이지 이용 시 언어 장벽으로 인해 위험 정보를 제대로 인지하지 못하는 문제가 존재한다. 웹 뷰 기반 번역 기능을 통해 별도 번역 앱 사용 없이 즉시 정보 이해가 가능하도록 하여, 정보 접근 과정을 단축한다.

2.5. 주요 기능 리스트

(1) 머신러닝 기반 악성 URL 탐지악성 URL 판별: 기존의 URL 문자열 데이터 기반 분류 앙상블 모델 생성 후 해외여행 관련 URL 로 파인튜닝해 해외여행 도메인에 특화된 모델을 생성한다.

(2) 사용자 맞춤 위험 판단 근거 제시: 설명 가능한 AI(XAI)를 활용해 URL 길이, 특수문자 사용, 도메인 구조 등 모델이 중요하게 반영한 특징을 시각화하여 위험 원인을 직관적으로 설명한다.

(3) 리다이렉션 로그 추적: URL 접속 과정에서 발생하는 모든 HTTP 리다이렉션 경로를 순차적으로 추적하여 최종 도착 URL 과 중간 경유지를 함께 분석한다.

(4) 자바스크립트 실행 제어: WebView 의 javaScriptEnabled 속성을 사용하여 페이지 로드 시 JavaScript 실행을 기본적으로 차단한 상태로 로딩하고 페이지 안전성 검토 후 필요 시에만 실행을 허용한다.

(5) 페이지 번역: Google Cloud Translation API 를 활용하여 외국어로 제공되는 웹페이지 내용을 사용자가 쉽게 이해할 수 있도록 번역한다.

(6) 민감 정보 자동 감지: 입력 필드의 구조와 텍스트를 데이터베이스 기반으로 분석하여 개인정보 입력 유도 여부를 판단하고, 위험이 감지될 경우 사용자에게 경고 메시지를 제공한다.

3. 과제 설계

3.1. 요구사항 정의

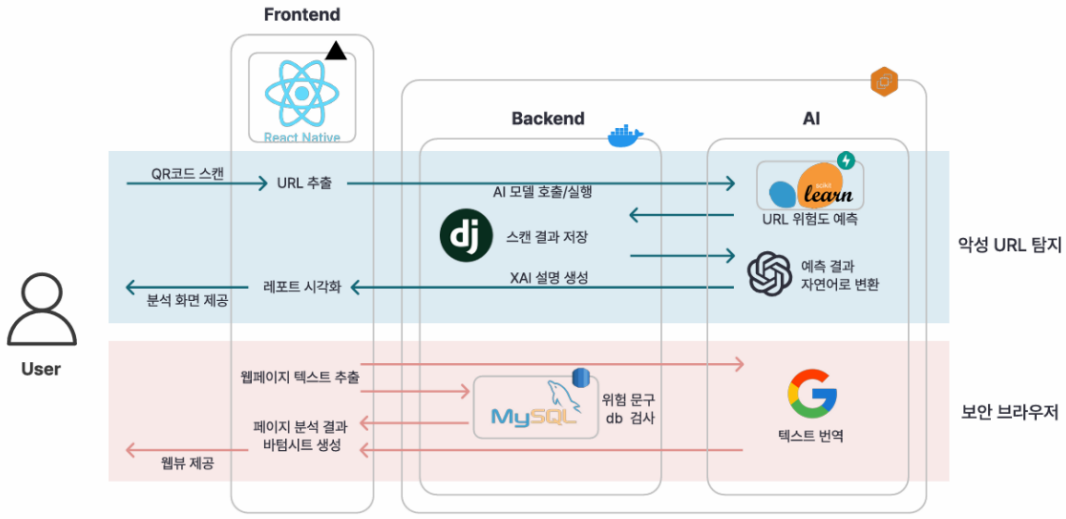
페이지 단위로 작성한 주요 기능 명세서는 아래와 같다.

페이지	기능	기능 설명
온보딩	서비스 주요 기능 및 사용 흐름 안내	악성 URL 탐지, 위험 경고, 세이프존 브라우저 기능 등 핵심 보안 기능을 시각적으로 설명함. 사용자가 별도의 보안 지식 없이도 서비스 목적과 사용 방법을 직관적으로 이해할 수 있도록 구성
여행 정보 입력	사용자 여행 정보 입력 및 개인화 보안 환경 설정	사용자가 여행 중인 국가, 도시, 여행 기간을 입력하여 서비스 이용 환경을 설정. 입력된 정보는 이후 기능에서 다음과 같이 활용됨 1) 여행 안전도 지표 제공 2) 최근 스캔 활동 기록과 연동 3) 상황 기반 보안 대응 정보(긴급 신고 및 대응 기관 정보 및 피해 발생 시 대응 가이드) 제공
QR 인식	QR 코드 인식 및 URL 추출	인식된 QR 정보는 자동으로 URL 분석 기능과 연동되어 사용자가 별도의 추가 작업 없이 즉시 보안 검사를 수행할 수 있도록 함
URL 안전성 분식 및 결과 제공	QR 코드 스캔 또는 URL 입력 시, AI 기반 모델을 통해 해당 URL 의 위험도를 분석	분석 결과를 정상/악성으로 구분하여 시각적으로 표시. 단순 결과 제공에 그치지 않고, 사용자가 판단 근거를 이해할 수 있도록 다음 정보를 함께 제공 1) 리다이렉션 로그 제공 2) AI 기반 위험 판단 근거 제공(XAI)
	사용자 선택에 따라 다음 행동을 유도 1) 정상 판별의 경우, ‘보안 브라우저로 열기’ 버튼 클릭 시 세이프존 브라우저로 연결	

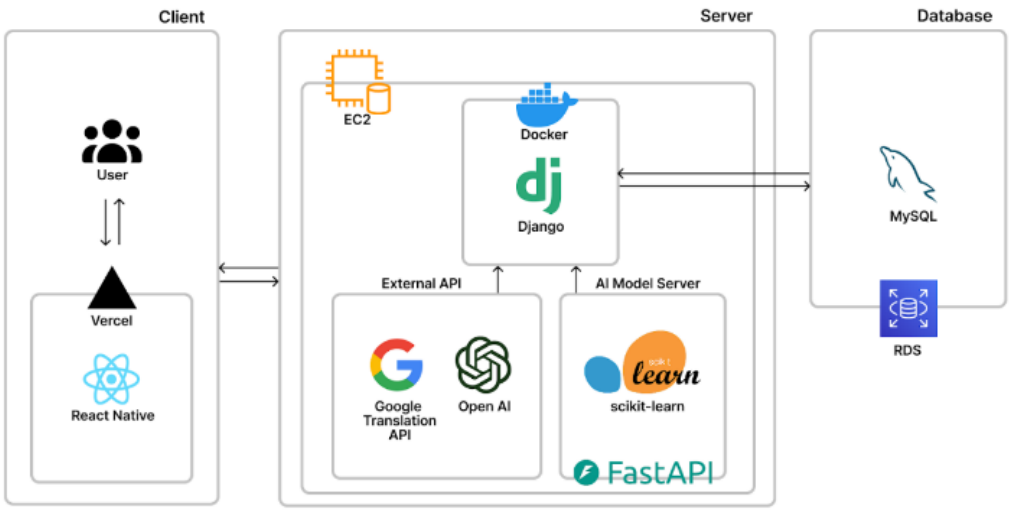
	2) 악성 판별의 경우, 경고 팝업 제공 후 기본적으로 접근 차단	
세이프존 브라우저 ON/OFF	사용자가 URL 에 접속하는 경우 자동으로 세이프존 브라우저 활성화	페이지 로드 시 다음 기능이 자동으로 적용 1) 위험 문구 탐지(로그인 유도, 결제 요청 등 피싱 의심 요소 식별) 2) 실시간 번역 기능 제공(외국어 콘텐츠 이해 지원)

3.2. 전체 시스템의 구성

3.2.1. 전체 시스템 개념도



3.2.2. 시스템 구조도



3.3. 주요 개발 내용

3.3.1. AI 모델 제작 및 피처 엔지니어링

본 프로젝트는 QR 코드 스캔을 통해 추출된 URL 이 정상 사이트인지, 피싱 사이트인지 판별하기 위해 머신러닝 기반의 악성 URL 탐지 모델을 핵심 기술로 사용한다. 그 중에서도 RandomForest Classifier 를 주력 모델로 적용한다.

A. 피처 엔지니어링

모델 학습에 사용한 피처는 24 개의 문자열 피처이다. 문자열 피처는 각 URL 이 가지는 구조적 특성을 정량화해 악성 여부를 학습하는 데 활용된다. 악성 URL 은 대부분 길이가 길다는 특성과, 복잡한 서브도메인·IP 주소 기반으로 위장하기 위해 특수 문자가 과도하게 사용될 수 있다는 특성 등을 고려하여 구성된 피처들이다. 또한 문자열 패턴만으로는 URL 의 숨겨진 특성이나 정교한 공격 패턴을 충분히 구분하기 어렵다는 한계를 극복하기 위해 메타데이터 피처를 도입한다. 도메인 생성일 및 만료일, 수명 등이 이에 해당된다.

① 길이(length) 기반 피처

- len_URL: 전체 URL 길이
- len_hostname: 호스트명 길이
- len_TLD: 최상위 도메인(TLD) 길이
- len_path: path 길이
- len_first_dir: 첫 번째 디렉토리 이름 길이

② 구조(structure) 기반 피처

- URL_depth: 경로(path)의 디렉토리 깊이
- num_subdomains: 서브도메인 개수
- is_ip: IP 주소 사용 여부
- is_short_URL: 단축 URL 여부

③ 문자(character) 및 특수문자 기반 피처

- URL_depth: 경로(path)의 디렉토리 깊이
- num_digits: 숫자 수
- num_letters: 알파벳 수
- num_http, num_https, num_www: 특정 문자열 등장 횟수

- num_@, num_?, num_&, num_%, num_#, num_., num_=, num__, num_-:

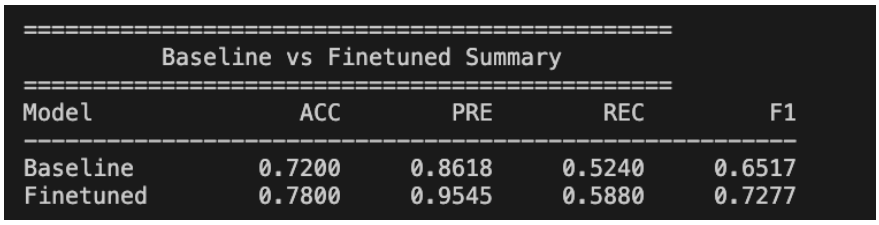
  특수문자 등장 횟수

- num_hostname_-: 호스트명 내 '-' 등장 횟수

B. 도메인 파인튜닝

baseline 모델은 전반적인 정상·악성 URL 패턴을 높은 정확도로 학습하고 있으나, 여행 도메인만의 고유한 패턴은 충분히 반영되지 않았다는 한계가 존재한다. 따라서 baseline 모델만으로는 여행 환경에서 발생하는 공격 시나리오 전체를 포괄하기에 한계가 있으며, 이를 보완하기 위해 해외여행 특화 데이터를 추가적으로 학습시키는 파인튜닝을 진행하였다.

3.3.2. 1, 2 차 RF 단일 모델 실험



```
================================================
          Baseline vs Finetuned Summary
================================================
Model               ACC        PRE        REC         F1
------------------------------------------------------------
Baseline         0.7200     0.8618     0.5240     0.6517
Finetuned        0.7800     0.9545     0.5880     0.7277
```

제한된 데이터 기반의 1 차 실험 이후, 데이터셋을 확장하여 2 차 실험을 수행하였다. 2 차 실험의 결과 fine-tuned 모델이 모든 주요 지표에서 baseline 보다 더 나은 성능을 보였다는 점에서 의미 있었으나, 전반적인 성능이 1 차보다 떨어진 점이 발견되었다.

이러한 현상의 원인을 분석해본 결과, 1 차 학습 데이터는 비교적 단순 구조에 편중되어 있어 트리 기반 모델이 정상·악성 패턴을 빠르게 학습하기 쉬웠다. 그러나 2 차 실험의 데이터 확장 과정에서 정상 URL 의 다양성이 증가하여 분류 난이도가 상승하였다. 2 차 실험에서 정상 URL 8,000 개를 확장하면서 다음과 같은 변화로 인해 정확도가 감소하였음을 확인할 수 있었다.

- path depth 다양화
- 쿼리 파라미터 구조 증가
- 다국적 도메인 포함
- 긴 URL + 복잡한 구조 증가

그러나 오히려 이러한 2 차 실험의 결과가 1 차 모델의 높은 성능이 실제 성능이 아니라 데이터 편향과 구조 단순성에서 비롯된 overfitting 이었다는 것의 반증이라고 판단하였다.

3.3.3. RF 단일 모델의 한계

RF 모델은 구현이 비교적 간단하고 안정적인 성능을 보이기 때문에, 초기 실험 단계에서 모델의 전반적인 성능 경향을 파악하고 피처의 유효성을 검증하는 데 적절한 선택이었다. 그러나 학습 데이터의 양을 늘려 진행한 2 차 실험의 결과, 해당 Accuracy 수준은 실제 서비스에 적용하기에는 여전히 부족한 것으로 판단되었다.

3.3.4. 앙상블 적용 배경

이에 대해 단일 모델 기반 접근만으로는 데이터 규모가 확장될 경우 성능 향상에 한계가 존재할 수 있다는 점이 지적되었고, 모델의 기본적인 capacity 를 높이기 위해 보다 다양한 모델을 실험하거나, 서로 다른 특성을 가진 모델을 결합하는 앙상블 기법을 적용하는 방안을 고려하게 되었다. 또한, 향후 학습 데이터 규모 확장, 해외여행 특화 데이터 추가, 메타데이터 기반 피처 확장이 예정되어 있다는 점을 고려할 때, 단일 모델보다 다양한 패턴을 포착할 수 있는 구조가 필요하다고 판단하였다

3.3.5. 앙상블 진행 과정

앙상블 모델 구성을 위해 서로 다른 학습 방식과 특성을 갖는 세 가지 후보 모델(XGBoost, LightGBM, SVM)을 선정하였다. 이를 통해 각 모델의 장점을 결합하고 성능 향상을 도모하고자 하였다.

앙상블 후보 모델에 대해서는 Random Forest 모델에 수행한 2 차 실험과 동일한 학습 데이터셋 및 테스트 데이터셋을 사용하여 개별 모델의 성능을 평가하였다. 사용된 데이터셋은 다음과 같다.

(1) Baseline 모델 학습
- 정상 URL 데이터 8,000 개
- 악성 URL 데이터 8,000 개

(2) Fine-tuned 모델 학습
- 정상 URL 데이터 400 개
- 악성 URL 데이터 400 개

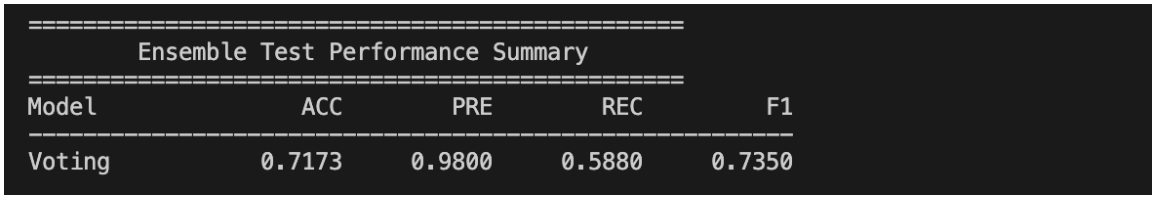
(3) 테스트 데이터셋
- 정상 URL 데이터 250 개
- 악성 URL 데이터 250 개

앙상블 모델은 서로 다른 학습 전략을 가지는 모델들을 결합할 때 성능 향상을 기대할 수 있기에 RandomForest, XGBoost, LightGBM 세 가지 모델을 선택하였다. 또한, 선행 연구를 통해 다수 모델을 조합하는 앙상블 방식의 경우 전체 예측 소요 시간은 모델 중 가장 시간이 오래 걸리는 모델에 종속된다는 점을 확인하였다. 이에 따라, Randomforest, XGBoost, LightGBM 모델과 비교하여 성능 차이가 크지 않으면서 계산 비용이 높은 SVM 모델은 앙상블에서 제외하였다.

앙상블 방식으로는 Voting 과 Stacking 두 가지를 고려하였다. Voting 방식은 여러 모델의 예측 결과를 결합하여 최종 예측을 도출하는 기본적인 앙상블 기법으로, 구현이 간단하면서도 안정적인 성능 향상을 기대할 수 있다. Voting 방식 중 Soft Voting 과 Weighted Voting 을 비교한 결과, 세 단일 모델의 성능이 유사한 수준이었기 때문에 특정 모델에 가중치를 부여하는 것은 큰

의미가 없다고 판단하였다. 이에 따라 각 모델의 예측 확률을 평균하여 최종 결과를 도출하는 Soft Voting 방식을 적용하였다. 한편, Stacking 방식은 각 모델의 예측 결과를 메타 모델이 다시 학습하는 구조로, 모델 간 상호 보완적인 패턴을 반영할 수 있다는 점에서 적용하였다.

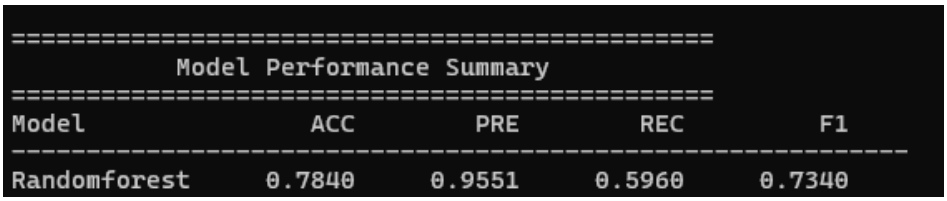
A. Voting 앙상블



```
================================================
        Ensemble Test Performance Summary
================================================
Model               ACC        PRE        REC        F1
------------------------------------------------------------
Voting           0.7173     0.9800     0.5880     0.7350
```

Voting 기반 앙상블 모델의 테스트 결과, Accuracy 는 0.717 로 나타났다. Precision 은 0.98 로 매우 높았으나, Recall 은 0.588 로 상대적으로 낮은 값을 보였다. 이는 모델이 악성 URL 을 보수적으로 판단하면서 일부를 정상으로 분류하는 경향이 있음을 의미한다. 결과적으로 F1-score 또한 0.753 수준에 머물렀다. 이러한 결과는 단일 모델 대비 성능 향상이 나타나지 않았음을 보여주며, 단순한 모델 결합만으로는 성능 개선이 이루어지기 어려울 수 있음을 시사한다.

B. Stacking 앙상블



```
================================================
          Model Performance Summary
================================================
Model               ACC        PRE        REC        F1
------------------------------------------------------------
Randomforest     0.7840     0.9551     0.5960     0.7340
```

Stacking 기반 앙상블 모델의 테스트 결과, Accuracy 는 0.786 으로 나타났다. Precision 은 0.8907 로 비교적 높은 값을 유지하여, 악성 URL 로 판단한 경우 실제로 악성일 확률이 높은 것으로 나타났다. 반면 Recall 은 0.652 로 상대적으로 낮은 수치를 보여, 일부 악성 URL 을 놓치는 경향이 있음을 확인할 수 있다. 이에 따라 F1-score 는 0.7529 수준으로, Precision 대비 Recall 의 부족이 전체 성능을 제한하는 요인으로 작용하였다. 이러한 결과는 Stacking 모델이 기존 단일 모델(Random Forest, XGBoost, LightGBM) 대비 Recall 과 F1-score 측면에서 일부 개선을 보였으나, 여전히 악성 탐지 관점에서는 탐지율 향상이 추가적으로 필요함을 시사한다.

3.3.6. 앙상블 결과 분석

세 개의 파인튜닝된 모델을 2 가지의 방법으로 앙상블을 시도했으나, 개별 모델 대비 유의미한 성능 향상은 확인되지 않았다. 일반적으로 앙상블 기법이 효과를 발휘하기 위해서는 각 모델이 서로 다른 오류 패턴을 가져야 한다. 즉, 동일한 데이터에 대해 서로 다른 예측을 수행함으로써 개별 모델의 약점을 보완할 수 있어야 한다. 따라서 앙상블에서 성능 개선이 나타나지 않았다는 것은, 동일한 데이터에 대해 모델 간 예측 결과의 차이가 크지 않았기 때문일 것이라는 가설을 세웠다. 이를 검증하기 위해 각 단일 모델의 prediction 결과를 비교하여, 모델 간 예측 차이가

얼마나 존재하는지 분석하였다. 특히 동일 샘플에 대해 서로 다른 예측을 수행한 케이스를 중심으로 모델 간 다양성을 확인해보았다.

각 단일 모델의 예측 결과를 비교했을 때, 전체 테스트 케이스 500 개 중 예측이 서로 달랐던 케이스는 27 개에 불과한 반면, 세 모델이 모두 동일하게 오답을 낸 케이스는 94 개로 훨씬 많은 비중을 차지하였다. 즉 서로 다른 예측을 통해 보완이 가능한 경우보다, 모든 모델이 동일하게 실패하는 경우가 압도적으로 많았다는 점에서 앙상블의 효과가 제한됐다고 볼 수 있다. 이는 모델들이 공통적으로 어려워하는 데이터 패턴이 존재함을 시사하며, 따라서 모델보다는 데이터 자체의 한계 또는 feature 표현의 부족 문제를 의심하게 되었다.

3.4. 피드백 및 발전 방향

3.4.1. 지도 교수님 피드백

앙상블 실험 진행 이후 전반적으로 앙상블 모델의 성능이 기대만큼 나타나지 않은 원인과 해석을 중심으로 지도 교수님과 면담을 진행하였다. 추가적인 모델 실험을 진행하는 것이 필요한지에 대해 질문하였고, 이에 대해 현재 시점에서는 모델 자체를 변경하거나 추가로 실험하는 것은 큰 의미가 없다는 답변을 들었다. 이미 다양한 모델과 앙상블 기법을 적용했음에도 성능 향상이 크지 않았다는 점에서, 이는 모델의 문제가 아니라 데이터의 한계에서 비롯된 것일 가능성이 높다는 의견이었다. 발전 방향에 있어, 메타데이터 기반 피처 추가와 데이터셋 재구성 중 어떤 방향을 우선적으로 개선하는 것이 효과적인지에 대해서도 질문하였고, 두 가지 모두 필요하지만 특히 피처 확장이 더 중요하다는 답변을 들었다. 또한, 일반적으로 앙상블은 단일 모델보다 성능이 나빠지기 어렵기 때문에 현재 결과에 대한 추가적인 확인이 필요하다는 피드백을 받았다.

3.4.2. 추후 발전 방향

전반적으로 이번 실험 결과는 모델의 종류나 구조의 문제가 아니라 데이터의 질과 다양성 부족에서 비롯된 한계로 해석할 수 있으며, 향후에는 데이터 측면에서의 개선이 우선적으로 이루어져야 한다는 방향성을 도출하였다. 따라서 향후 진행 계획은 다음과 같다.

(1) 메타데이터 피처 활용

URL 의 문자열 기반 특징뿐 만 아니라 도메인 생성 시점, 인증서 정보와 같은 메타 데이터 기반 피처를 추가적으로 활용하여 학습 피처를 다양화할 필요가 있다. 이를 통해 모델이 보다 다양한 관점에서 URL 을 판단할 수 있도록 개선할 수 있을 것으로 기대된다.

(2) 학습 데이터셋 재구성

기존 데이터셋은 특정 유형의 URL 에 편중되어 있을 가능성이 있으며 이는 모델의 일반화 성능을 제한하는 원인이 될 수 있다. 따라서 다양한 출처의 데이터를 수집하고, 데이터 분포를 재구성하거나 노이즈 데이터를 정제하는 등 전처리 과정을 보다 체계적으로 수행할 필요가 있다